

ゼロコストプロキシは入力データを見ているか

NAS-Bench-201 における乱数入力置換の事前登録付き検証

AIRAS 自動研究システム

実験実行（予定）：RIKYU (NVIDIA GB200, aarch64) via Seyval / 評価: `airas-eval nas_pre_training`

2026 年 9 月 2 日（事前登録版：実験実行前に凍結）

Abstract

学習不要（training-free）のニューラルアーキテクチャ探索で用いられるゼロコストプロキシの多くは「単一ミニバッチの実データ」から計算されると説明され、その正当化も入力に対する応答に置かれている。しかし実データが予測力にどれだけ寄与しているかは定量化されていない。Mellor ら [5] は乱数入力でも「傾向が変わらない」ことを 10 アーキテクチャの箱ひげ図で定性的に示したのみである。本研究は、プロキシに渡す入力だけを実 CIFAR-10 ミニバッチから同形状・同統計の標準正規ノイズに置換するという最小介入により、入力データの実効的寄与を順位相関の差 $\Delta\rho = \rho_{\text{real}} - \rho_{\text{rand}}$ として定量する。NAS-Bench-201 [2] から固定シードで抽出した 1,000 アーキテクチャを対象とし、真値は同ベンチマークの公表テスト精度を参照するのみで、アーキテクチャの学習は一切行わない（0 エポック）。中心となる主張は `jacob_cov` の $\Delta\rho$ が 0.10 を超えないことである。構成上入力を使わない `synflow` をデータ非依存対照とし、初期化シードのみを変えた複製ランをノイズ床として置き、さらにスコア水準の操作チェックを併置することで、「順位が動かない」ことが「介入が届いていない」ことの帰結でないことを保証する。すべての指標は外部の固定された評価層 `airas-eval` が算出し、実験コードは指標を一切計算しない。

1 はじめに

ニューラルアーキテクチャ探索（NAS）の評価段階を高速化する手法として、学習を全く行わずにアーキテクチャを採点するゼロコストプロキシ（zero-cost proxy, 以下 ZC プロキシ）が広く使われている [1, 5]。これらは典型的には「学習データの単一ミニバッチを 1 回だけ順伝播・逆伝播させ、その勾配や活性から算出したスカラー」であり、その設計思想は「入力に対するネットワークの応答が、学習後の性能を予告する」という仮定に立っている。

この仮定は、しかし、正面から検証されていない。むしろ疑う理由が二つある。

第一に、Abdelfattah ら [1] の `synflow` は、損失を「全パラメータの積」として定義するため入力データを一切必要としない。にもかかわらず、NAS-Bench-201 の CIFAR-10 において、同論文が比較した単一プロキシの中で最も高い Spearman 順位相関 0.74 を示す。データを見ないプロキシが、データを見るプロキシより良いのである。

第二に、Yang ら [7] は、learning-free 指標の順位付け能力の大部分がパラメータ数 `#Param` との相関に由来することを示した。NAS-Bench-201 における `#Param` との Kendall τ は最大 0.56 に達し、パラメータ数を揃えた部分空間では各指標の探索性能が劇的に低下する。

両者を合わせると、「ZC プロキシが実際に測っているのは入力への応答ではなく、アーキテクチャ固有の量（規模・接続構造）ではないか」という仮説が立つ。本研究はこの仮説を、入力データ側を直接統制する介入によって検証する。

2 関連研究と本研究が埋める空白

ゼロコストプロキシ. Abdelfattah ら [1] は枝刈り文献の saliency 指標 (snip [4], grasp, synflow [6], fisher) をネットワーク全体の採点に転用し、Mellor ら [5] の jacob_cov と合わせて NAS-Bench-201 の全 15,625 モデルで評価した。報告された CIFAR-10 の Spearman 順位相関は synflow 0.74、jacob_cov 0.73、grad_norm 0.58、snip 0.58、grasp 0.48、fisher 0.36 である (数値は同論文 Table 1 の引用であり、本研究の測定値ではない)。

入力依存性に触れた唯一の先行研究. Mellor ら [5] は NASWOT スコアの頑健性のアブレーションとして、CIFAR-100 の 10 アーキテクチャに正規乱数入力を与えた箱ひげ図を示し、「傾向はほぼ変わらない」と述べている。しかしこれは 10 個のアーキテクチャに関する定性的な観察であって、探索空間規模での順位相関としての定量化ではない。本研究はこの空白を、 $\Delta\rho$ という 1 つの数に還元して埋める。

バイアス分析. Krishnakumar ら [3] は 13 のプロキシを 28 タスクで統一実装のもと評価し、cell size などのバイアスを分析した。同研究が定めた「真の精度が上位 10% の候補に限定した順位相関」のプロトコルを本研究も支持指標として採用する。ただし同研究のバイアス分析はアーキテクチャ側に限られ、入力データ側の寄与は分析されていない。

本研究の位置づけ. Yang ら [7] がアーキテクチャ側 (#Param) を統制したのに対し、本研究は入力データ側を統制する。両者は相補的であり、「プロキシはアーキテクチャを測っておりデータを測っていない」という同一の結論に両側から接近する。

3 仮説と予測

以下の主張 C1–C5 は実験実行前に凍結したものである。各主張について、判定基準（これを満たさなければ棄却）と予測区間（期待される値の範囲）を分けて記す。判定基準は反証線であり、予測区間は期待である。予測区間を外れた結果は、判定基準を満たしていても第 7 節で論じる。

- C1** (中心仮説: jacob_cov の入力非依存性) jacob_cov の真の精度に対する順位付け能力は、入力を実 CIFAR-10 ミニバッチから $N(0, 1)$ 乱数テンソルに差し替えても実質的に変化しない。
判定基準: $|\Delta\rho_{\text{jacob_cov}}| \leq 0.10$ 。これを超えれば jacob_cov は実データを実質的に利用しており、本主張は棄却される。
予測区間: $\Delta\rho = 0.00\text{--}0.05$ 。根拠は Mellor ら [5] の定性的アブレーションと、Yang ら [7] が示した #Param 依存性。参考として ρ_{real} は文献値 0.73 前後を予測する。
実測: $\rho_{\text{real}} = 0.715$ 、 $\rho_{\text{rand}} = 0.604$ 、 $\Delta\rho = 0.110$ 。
- C2** (snip の入力非依存性) snip の順位付け能力も、入力を乱数テンソルに差し替えて実質的に変化しない。
判定基準: $|\Delta\rho_{\text{snip}}| \leq 0.10$ 。
予測区間: $\Delta\rho = 0.00\text{--}0.08$ 。snip は損失勾配を経由するため jacob_cov より入力依存が強い可能性があり、C1 より広い区間を置く。参考として ρ_{real} は文献値 0.58 前後を予測する。
実測: $\rho_{\text{real}} = 0.598$ 、 $\rho_{\text{rand}} = 0.646$ 、 $\Delta\rho = -0.048$ 。
- C3** (データ非依存対照: 実験系の健全性) synflow は構成上入力データを使わないため、入力条件を変えても順位相関は厳密に一致する。
判定基準: $|\Delta\rho_{\text{synflow}}| \leq 0.001$ 。これを超える場合、入力以外の要因が条件間で漏れていることを意味し、C1 と C2 の解釈は保留される。

予測区間: 0.000–0.001 (理論上は厳密に 0。浮動小数点の非決定性のみを許容)。根拠は Abdelfattah ら [1] 3.2.1 節の定義。

実測: $\rho_{\text{real}} = 0.794$ 、 $\rho_{\text{rand}} = 0.794$ 、 $\Delta\rho = 0.0000$ 。

- C4** (シードノイズ床との比較) 入力を実データから乱数に差し替えることの効果は、初期化シードを振り直すことの効果を超えない。

判定基準: $|\Delta\rho_{\text{jacob_cov}}| \leq |\Delta\rho_{\text{seed}}| + 0.05$ 。これを超えれば、入力差し替えはシード揺らぎでは説明できない固有の効果を持つことになり棄却される。

予測区間: $|\Delta\rho_{\text{seed}}| = 0.00\text{--}0.05$ 。1,000 アーキテクチャ $\times$ 3 シード平均のもとでのシード揺らぎとして見積もった区間であり、事前の文献値はない。

実測: $\rho_{\text{rep}} = 0.713$ 、 $\Delta\rho_{\text{seed}} = 0.002$ 、比較対象の $\Delta\rho_{\text{jacob_cov}} = 0.110$ 。

- C5** (スコア水準の操作チェック) 入力の差し替えは `jacob_cov` のスコア値そのものには実際に到達しており、順位相関が動かないことはスコアが動いていないことの帰結ではない。

判定基準: 乱数入力スコアと実入力スコアの Spearman 相関が 0.999 未満。0.999 以上であれば実験系が入力を差し替えていない疑いが強く、C1 の解釈は無効となる。

予測区間: 0.60–0.95。スコアは入力で動くが順位情報は大きく保たれるという想定に基づく区間であり、事前の文献値はない。

実測: 0.926。

4 手法

4.1 紹介

同一のアーキテクチャ集合・同一の初期化シードに対し、ZC プロキシの入力だけを次の 2 条件に差し替え、それ以外を完全に固定する。

- 実データ条件 (**cifar10**): CIFAR-10 学習集合から取ったミニバッチ (バッチサイズ 128)。
- 乱数条件 (**randinput**): 同一形状・同一の正規化統計を持つ $N(0,1)$ 乱数テンソル。

入力データの実効的寄与を、真の精度との Spearman 順位相関の差

$$\Delta\rho = \rho_{\text{real}} - \rho_{\text{rand}} \quad (1)$$

として定量する。 ρ はいずれもプロキシスコアと NAS-Bench-201 の公表テスト精度の間で測る。

4.2 評価対象のプロキシ

- **jacob_cov** [5]: ミニバッチ内の異なる入力誘導する活性・ヤコビアンに相関に基づく。設計上もっとも強く入力に依存すると想定されるため中心に置く。
- **snip** [4]: $|\partial L / \partial \theta \odot \theta|$ を全パラメータで総和したもの。損失勾配を経由して入力に依存する。
- **synflow** [6]: 損失を全パラメータの積として定義するため入力を使わない。データ非依存対照として置く。

データ漏洩を防ぐため、プロキシの計算にラベルは一切使用しない。

4.3 統制

順位が動かないという観察は、それ自体では「プロキシがデータを見ていない」ことを意味しない。実験系が入力を差し替え損ねていても同じ観察が得られるからである。これを排除するため 3 つの統制を置く。

1. データ非依存対照 (C3) : synflow は入力を使わないため $\Delta\rho$ は厳密に 0 でなければならない。
2. シードノイズ床 (C4) : 入力を実データに保ったまま初期化シード三つ組だけを $[0, 1, 2]$ から $[10, 11, 12]$ に変えた複製ランを走らせ、入力差し替えの効果を同じ尺度で比較する。
3. スコア水準の操作チェック (C5) : 乱数入力スコアを predicted、実入力スコアを reference として Spearman 相関を測り、「スコアは動くが順位相関は動かない」のか「スコアすら動いていない」のかを分離する。

5 実験設計

探索空間と真値. NAS-Bench-201 [2] (4 ノード 6 エッジの cell、演算 5 種、計 15,625 候補)。評価対象は固定シード 2026 で一様抽出した 1,000 アーキテクチャであり、全ランで同一の集合を用いる (条件間で比較可能にするための前提)。真値は同ベンチマークが公表する CIFAR-10 のテスト精度 (eval_acc1es) を参照するのみで、アーキテクチャの学習は一切行わない (0 エポック、順伝播・逆伝播 各 1 回のみ)。

ラン. プロキシ 3 種 $\times$ 入力条件 2 種に、シード複製ランと操作チェックランを加えた計 8 ラン。各ランは 3 つの初期化シードでプロキシを計算し、その平均をアーキテクチャのスコアとする。ラン ID は proposed-jacobcov-randinput (中心となる介入条件)、comparative-1-jacobcov-cifar10、comparative-2-jacobcov-cifar10rep、comparative-3-snip-cifar10、comparative-4-snip-randinput、comparative-5-synflow-cifar10、comparative-6-synflow-randinput、comparative-7-jacobcov-realvsrand である。

指標. 主要指標は Spearman 順位相関 spearman_rho、支持指標は kendall_tau、spearman_rho_top_10pct (真の上位 10% に限定した順位相関 [3])、precision_at_top_10pct。これらはすべて外部の固定された評価層 airas-eval の nas_pre_training タスクが算出する。実験コードは指標を一切計算せず、プロキシスコア predicted_scores と真値 reference_scores を書き出すのみである。どの指標を報告するかを選ぶ余地は設計上存在しない (タスク型が指標集合を決める)。

実行環境. RIKYU (BYO Slurm クラスタ、NVIDIA GB200、aarch64、partition=gpu) を Seyval 経由で使用する。CIFAR-10 と NAS-Bench-201 の参照表は同クラスタ上の既設キャッシュを読み取り専用で参照する。依存は uv.lock で固定し、リポジトリの Dockerfile をそのままビルドして実行するため、コミットハッシュだけで実行環境が決まる。スケールは sanity = 10 アーキテクチャ / 1 シード、pilot = 200 / 3 シード、full = 1,000 / 3 シードとする。

6 結果

全 8 ランは事前登録コミットの子孫にあたる単一コミットで実行され、指標はすべて外部の評価層 airas-eval が算出した。主要指標を表 1 と図 1 に示す。以下、主張 C1–C5 を第 3 節で凍結した判定基準に照らして順に報告する。判定基準と予測区間は実験実行前に凍結されており、結果に合わせて変更していない。

Table 1: NAS-Bench-201 (CIFAR-10, 1000 アーキテクチャ) 上の zero-cost proxy と真のテスト精度の順位相関。入力条件は実 CIFAR-10 ミニバッチ (cifar10) と $N(0,1)$ 乱数テンソル (randinput)。学習は一切行っていない。

	Spearman ρ	Kendall τ	ρ (top 10%)	P@top10%
jacob_cov / cifar10	0.715	0.555	0.370	0.210
jacob_cov / randinput	0.604	0.453	0.243	0.060
jacob_cov / cifar10 (seed rep.)	0.713	0.554	0.317	0.110
snip / cifar10	0.598	0.435	-0.220	0.390
snip / randinput	0.646	0.472	-0.168	0.360
synflow / cifar10	0.794	0.596	0.306	0.510
synflow / randinput	0.794	0.596	0.306	0.510

C1 (中心仮説 : **jacob_cov** の入力非依存性) — 棄却。 $\rho_{\text{real}} = 0.715$ 、 $\rho_{\text{rand}} = 0.604$ 、 $\Delta\rho = 0.110$ 。判定基準は $|\Delta\rho| \leq 0.10$ であり、実測値はこれを上回った。したがって本主張は棄却される。予測区間 0.00–0.05 から外れており、予測は二重に外した。なお ρ_{real} 自体は文献値 0.73 に近く、実装が標準的な jacob_cov を再現していることを示す。

C2 (**snip** の入力非依存性) — 支持。 $\rho_{\text{real}} = 0.598$ 、 $\rho_{\text{rand}} = 0.646$ 、 $\Delta\rho = -0.048$ 。 $|\Delta\rho| \leq 0.10$ を満たし、判定基準を通過した。符号が負である点は予測していなかった。すなわち乱数入力の方がわずかに良い。 ρ_{real} は文献値 0.58 に近い。

C3 (データ非依存対照) — 支持。 $\rho_{\text{real}} = 0.794$ 、 $\rho_{\text{rand}} = 0.794$ 、 $\Delta\rho = 0.0000$ 。判定基準 $|\Delta\rho| \leq 0.001$ を満たす。表 1 のとおり synflow の 2 条件は 4 指標すべてで完全に一致しており、アーキテクチャ抽出・採点・評価の経路が条件間で何の差も生んでいないことを意味する。C1 と C2 で観測された差は、この経路に由来するものではない。

C4 (シードノイズ床との比較) — 棄却。 入力を保ったまま初期化シードのみを変えた複製ランは $\rho_{\text{rep}} = 0.713$ を与え、 $\Delta\rho_{\text{seed}} = 0.002$ にとどまった。判定基準 $|\Delta\rho_{\text{jacob_cov}}| \leq |\Delta\rho_{\text{seed}}| + 0.05$ に対し、実測の $|\Delta\rho_{\text{jacob_cov}}| = 0.110$ はこれを大きく上回る。したがって本主張も棄却される。シード揺らぎは予測区間 0.00–0.05 の下端に収まるほど小さく、入力差し替えの効果はそれとは桁の違う大きさである。

C5 (スコア水準の操作チェック) — 支持。 乱数入力スコアと実入力スコアの Spearman 相関は 0.926 であり、判定基準 < 0.999 を満たす。介入はスコアそのものに到達しており、C1 の結果が「入力が差し替わっていなかった」ことの帰結でないことが確認された。一方でこの値は 1 から大きくは離れておらず、スコアの順位情報の大半は入力を変えても保たれている。

支持指標。 jacob_cov について、Kendall τ は $0.555 \rightarrow 0.453$ (差 0.102)、真の上位 10% に限定した Spearman ρ は $0.370 \rightarrow 0.243$ (差 0.126)、上位 10% の一致率は $0.210 \rightarrow 0.060$ であった。いずれも主要指標と同じ向きで、実データ条件が優る。ただし上位 10% 系の指標はシード複製ランでも大きく動いており (表 1)、主要指標ほど安定していない。この 2 つの差は主要指標ほどの重みでは読めない。




Figure 1: 入力条件ごとの Spearman 順位相関。学習は一切行っていない。synflow の 2 本は構成上入力を使わないため厳密に一致する（データ非依存対照）。

7 考察

中心仮説は棄却された。しかし一様にはではない。本研究が凍結した中心仮説——ZC プロキシの順位付け能力は入力データの内容に依存しない——は、jacob_cov については成り立たなかった（C1, C4）。一方 snip については成り立った（C2）。したがって「ZC プロキシはデータを見ていない」という一般命題は誤りであり、正しい問いはどのプロキシがどれだけ見ているかである。

この結論は設計から見れば後付けで納得のいくものである。jacob_cov は定義上、ミニバッチ内の異なる入力誘導するヤコビアン相関であり、入力集合の構造そのものを測っている。自然画像は互いに相関を持つが、独立な $N(0,1)$ テンソルは持たない。差が出る方が自然である。対して snip の $|\partial L / \partial \theta \odot \theta|$ は、勾配の大きさを全パラメータで総和した量であり、入力の内容よりもネットワークの規模と接続構造に支配される。

最良のプロキシはデータを一切見ていない。本研究で最も高い順位相関を示したのは synflow (0.794) であり、これは構成上入力データを一度も参照しない。jacob_cov が実データを使って到達する 0.715 を上回っている。Yang ら [7] は training-free 指標の性能の多くが #Param との相関に由来すると論じたが、本研究の結果はそれと整合する形で、データを見ないことが性能上の不利にならない——むしろ本探索空間では有利ですらある——ことを示す。「入力に対する応答を測っているから効く」という説明は、少なくとも本探索空間においては、プロキシの性能を説明していない。

先行研究との関係。Mellor ら [5] は乱数入力で「傾向はほぼ変わらない」と報告したが、それは CIFAR-100 の 10 アーキテクチャに対する箱ひげ図の観察であった。1,000 アーキテクチャの順位相関として定量すると、jacob_cov の $\Delta\rho$ は事前に置いた判定基準 0.10 を超える。定性的な「ほぼ変わらない」と、順位相関としての「変わる」は矛盾しない——スコア分布の見かけが保たれていても

順位は崩れうる。実際 C5 が示すとおり、実入力と乱数入力のスコアは相関 0.926 で強く結びついており、それでもなお真の精度との順位相関には無視できない差が出る。本研究の寄与は、この差に数値と判定基準を与えた点にある。

判定基準の際どさについて、C1 の実測値 0.110 は判定基準 0.10 をわずかに超えたにすぎず、基準が 0.15 であれば結論は逆になっていた。この際どさは正直に記録されるべきである。ただし C4 はその解釈を助ける。シードのみを変えた複製ランの $\Delta\rho_{\text{seed}} = 0.002$ と比べると、入力差し替えの効果はノイズ水準では説明できない。C1 が僅差で棄却されたことと、効果がノイズより明確に大きいことは両立しており、「効果は実在するが小さい」というのが妥当な読み方である。

実務上の含意。探索の初期スクリーニングに ZC プロキシを使うなら、synflow のようにデータを参照しないプロキシは入力の選択に神経を使う必要がない。jacob_cov を使う場合は、渡すミニバッチが対象タスクの実データであることが順位品質に効く。ただしその差は本探索空間では $\Delta\rho \approx 0.110$ であり、プロキシの選択 (synflow と snip の差は主要指標で 0.794 対 0.598) の方が大きい。どのデータを渡すかより、どのプロキシを使うかの方が効く。

References

- [1] Mohamed S. Abdelfattah, Abhinav Mehrotra, Łukasz Dudziak, and Nicholas D. Lane. Zero-cost proxies for lightweight NAS. In *International Conference on Learning Representations (ICLR)*, 2021.
- [2] Xuanyi Dong and Yi Yang. NAS-Bench-201: Extending the scope of reproducible neural architecture search. In *International Conference on Learning Representations (ICLR)*, 2020.
- [3] Arjun Krishnakumar, Colin White, Arber Zela, Renbo Tu, Mahmoud Safari, and Frank Hutter. NAS-Bench-Suite-Zero: Accelerating research on zero cost proxies. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [4] Namhoon Lee, Thalaiyasingam Ajanthan, and Philip H. S. Torr. SNIP: Single-shot network pruning based on connection sensitivity. In *International Conference on Learning Representations (ICLR)*, 2019.
- [5] Joseph Mellor, Jack Turner, Amos Storkey, and Elliot J. Crowley. Neural architecture search without training. In *International Conference on Machine Learning (ICML)*, 2021.
- [6] Hidenori Tanaka, Daniel Kunin, Daniel L. K. Yamins, and Surya Ganguli. Pruning neural networks without any data by iteratively conserving synaptic flow. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [7] Taojiannan Yang, Linjie Yang, Xiaojie Jin, and Chen Chen. Revisiting training-free NAS metrics: An efficient training-based method. In *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2023.